ИУ7-51Б, 03_ZHA, Вылегжанина Алёна

Временные ряды

Хранение:

- Cassandra.

Прогнозирование:

- модель на цепях Маркова (Markov Chains);
- модель по выборке максимального подобия (MMSP).

Введение:

В философском смысле сама жизнь - это движение, то есть процесс.

Мы включены в разнообразные процессы: изменение уровня глюкозы в крови, появление солнечных пятен, изменение цен акций и многие другие. Независимо от того являемся ли мы их источником или участником, или просто подвержены влиянию этих процессов нам требуются технологии наблюдения, анализа и прогнозирования явлений, описываемых большим объёмом информации.

Задача воспроизведения источника информации с целью анализа данных, поиска основных закономерностей и структур, а также прогнозирования возможных будущих значений решается посредством использования временных рядов [1].

Под временным рядом подразумевается последовательность наблюдений некоторого признака (случайной величины) x в последовательные моменты времени [2]. Элементы временного ряда включают в себя два обязательных параметра: отметку времени и значение показателя ряда, соответствующее указанной отметке времени [9].

Область применения временных рядов охватывает различные сферы: экономику [8, 10, 12, 13], биологию [11], сейсмологию [14], программирование [15] и т.д..

На рисунке 1 представлен пример временного ряда цен на электроэнергию европейской территории РФ.

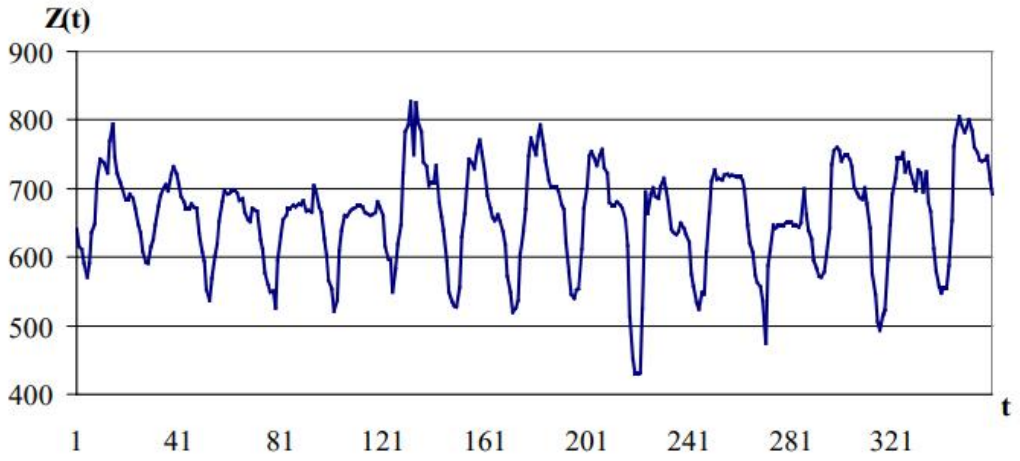


Рисунок 1. временной ряда цен на электроэнергию европейской территории РФ (в условных денежных единицах) [9].

Временные ряды дают возможность предугадать динамику отслеживаемых процессов. Прогноз основывается на данных, которые фиксируются на протяжении некоторого времени, что требует организации их хранения.

В данной работе будут рассмотрены некоторые методы хранения и прогнозирования временных рядов.

Методы хранения.

Необходимым условием для работы с временными рядами является организация хранения отслеживаемых данных.

В силу особенностей временных рядов и их обработки обозначим ключевые требования к средствам их хранения:

- приоритетность скорости записи данных, так как операции записи преобладают над операциями чтения [7];
- упорядоченность хранимых данных по времени, так как данные записываются, считываются и обновляются не случайным образом, а во временном порядке [7];
- расширяемость и вместительность хранилища данных;
- гарантия сохранности данных.

В данной работе в качестве методов хранения выделим и рассмотрим следующие подходы:

- использование нереляционных БД - Cassandra;
- использование специализированных для временных рядов баз данных - TSDB (тема другого члена группы)
- использование обычных файлов (тема другого члена группы).

Cassandra

Одним из способов хранения временных рядов является использование Apache Cassandra - базы данных, которая является:

- *распределенной* - обеспечивает работу на нескольких машинах, в дальнейшем называемых узлами, которые пользователем представляются как единое целое [3];
- *децентрализованной* - все узлы являются равноправными [3];
- *эластично масштабируемой* - обеспечивает возможность добавлять и убирать узлы, не прерывая работы системы. Данное свойство является специальным для горизонтальной масштабируемости - механического увеличения пропускной способности оборудования путём добавления памяти в уже имеющуюся машину [3];

- *отказоустойчивой* - предполагает замену повреждённых узлов без простоя, за счёт их репликации на несколько узлов [3] (репликация представляет собой набор технологий копирования и распространения данных и объектов между узлами, а также включает синхронизацию этих узлов для поддержания их согласованности (согласованность означает, что операция чтения всегда возвращает последнее записанное значение) [3, 4]);
- *допускающей настройку согласованности* - существует возможность настроить количество узлов, которые должны подтвердить завершение операции обновления данных [3].

Основными структурами данных в Cassandra являются:

- *столбец* - пара имя-значение;
- *строка* - контейнер для упорядоченной коллекции столбцов на которые можно сослаться по первичному ключу;
- *таблица* - контейнер для упорядоченной коллекции строк;
- *пространство ключей* - контейнер таблиц;
- *кластер* - контейнер пространств ключей, расположенных в одном или нескольких узлах [3].

Таким образом, столбец - самая элементарная структурная единица в модели данных Cassandra, и ему присущи следующие характеристики:

- имя;
- значение;
- тип;
- временная метка, генерируемая при каждом обновлении столбца;
- время жизни, указывающее срок хранения значения столбца [3].

Уточнив основные понятия базы данных, рассмотрим особенности Cassandra применительно к хранению временных рядов.

Модель данных организует хранение временного ряда, где *ключ для строки* – имя для нашего измерения, *имя столбца* – время измерения, *значение столбца* – измеренное значение [5]. Данная структура позволяет выбрать как индивидуальное значение, так и набор значений для заданного интервала какого-либо измерения [5].

Кроме того, для каждого столбца хранится время жизни, позволяющее автоматизировать процесс удаления устаревших данных, а также временная метка, которая используется с целью:

- разрешения конфликтов при изменении одного и того же значения со стороны нескольких клиентов [3];
- организации автоматической сортировки данных по времени [5].

В случае обработки временных рядов скорость поступления данных имеет большее значение, нежели скорость их изменения, потому что информация однородна и фактически обрабатывается только небольшая часть из всего объёма хранимой информации [5]. Данные особенности позволяют выделить Cassandra, как нереляционную БД (скорость добавления данных в NoSQL системах выше, чем в SQL системах) [5].

Cassandra является распределённой и децентрализованной, вследствие этого можно выделить следующие её аспекты:

- отказоустойчивость - гарантия сохранности информации за счёт репликации [6];
- масштабируемость - увеличение объёма хранимых данных возможно посредством добавления узла в кластер [6];
- слабая согласованность данных - отсутствие контроля актуальности читаемой информации [3]. Данная особенность может быть скорректирована настройкой согласованности.

Прогнозирование

Под прогнозированием, в широком смысле, понимают предсказание будущего с помощью научных методов [9]. Необходимо различать два взаимосвязанных понятия — метод прогнозирования и модель прогнозирования.

Метод прогнозирования представляет собой последовательность действий, которые нужно совершить для получения модели прогнозирования временного ряда [9].

Модель прогнозирования есть представление зависимости будущего значения от прошлого [9, 13], при этом способ задания этой зависимости может быть различным.

В *статистических* моделях функциональная зависимость между будущими и фактическими значениями временного ряда, а также внешними факторами *задана аналитически [9]*.

К статистическим относятся следующие группы моделей:

- регрессионные;
- авторегрессионные ;
- по выборке максимального подобия;
- экспоненциального сглаживания [9].

В *структурных* моделях зависимость будущего значения от прошлого задаётся в виде некоторой *структуры* и правил *перехода* по ней [9, 13].

К структурным относятся следующие группы моделей:

- нейросетевые;
- на базе цепей Маркова;
- на базе классификационно-регрессионных деревьев [9].

Необходимо отметить, что названия моделей и соответствующих методов как правило совпадают [9].

На основе полученных и хранимых данных прогнозируется дальнейшее поведение временных рядов. В нашей работе будут рассмотрены следующие методы:

- модель экспоненциального сглаживания (тема другого члена группы);
- модель на цепях Маркова;
- регрессионная модель(тема другого члена группы)
- авторегрессионные модели:
  - ARIMAX (тема другого члена группы);
  - GARCH (тема другого члена группы);
  - ARDLM (тема другого члена группы);
  - модель по выборке максимального подобия;
- модель на классификационно-регрессионных деревьях (тема другого члена группы).

Модель на цепях Маркова.

Цепь Маркова — это математическая модель, которая используется для моделирования случайных процессов, происходящих в течение определённого периода времени [8, 9, 13, 16]. Она состоит из набора состояний и переходов между ними [9, 16]. Возможность перехода из одного состояния в другое зависит исключительно от текущего состояния, а не от каких-либо прошлых событий. Данное условие также называют *марковским свойством* процесса [8, 9, 13, 16].

Пример цепи Маркова для процесса, имеющего три состояния, представлен на рисунке 2, где S1 ,S2 , S3 — состояния процесса Z(t), а вероятность перехода из состояния

S1 в S2 равна 0.5 ,
S2 в S1 равна 0.0,
S1 в S3 равна 0.25,
S3 в S2 равна 0.33 и т.д..

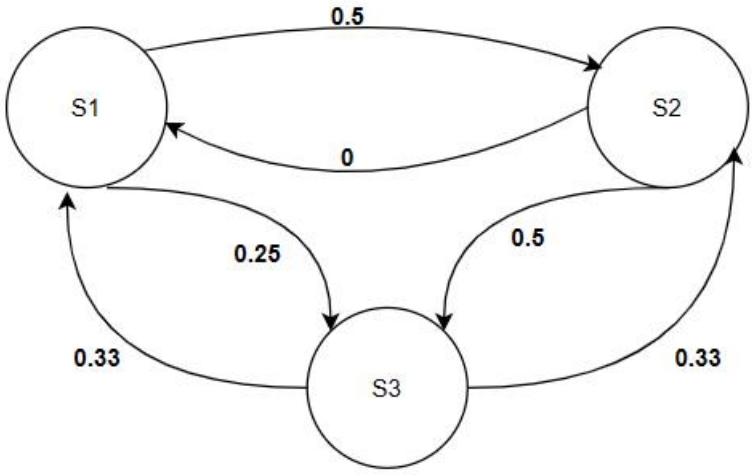


Рисунок 2. Цепь Маркова.

Для расчёта динамики цепи достаточно рассмотреть два аспекта:

- *вектор исходного распределения вероятностей A* - вектор, каждое i-ое значение в котором, соответствует вероятности того, что система находится в i-ом состоянии [1]. Например, для модели из трёх состояний:

$$A = (0.0, 0.5, 0.5)$$

- *матрицу переходных вероятностей P,* представляющую собой матрицу, каждое значение (i, j) которой соответствует вероятности того, что элемент перейдет из состояния s_i в состояние s_j на следующем шаге процесса [1]. Например, для модели на рисунке выше

$$P = \begin{pmatrix} 0.25 & 0.50 & 0.25 \\ 0.00 & 0.50 & 0.50 \\ 0.33 & 0.33 & 0.33 \end{pmatrix}$$

Чтобы определить вектор распределения вероятностей на следующем шаге необходимо вычислить произведение вектора A и матрицы P [13]. Для рассматриваемого примера:

$$(0.0, 0.5, 0.5)\begin{pmatrix} 0.25 & 0.50 & 0.25 \\ 0.00 & 0.50 & 0.50 \\ 0.33 & 0.33 & 0.33 \end{pmatrix} = (0.165, 0.415, 0.420)$$

Следовательно, вероятность того, что цепь находится в состоянии s_i после n шагов, является i-ой записью в векторе [1]:

$$A_n = A_{n-1}P$$

Основные этапы алгоритма построения модели временного ряда на цепях Маркова:

1) выделить состояния временного ряда;

2) проверить, можно ли считать рассматриваемый процесс Марковским;

3) вычислить матрицу переходных вероятностей;

4) определить вероятностный вектор, представляющий некоторое начальное распределение;

5) вычислить произведение матрицы и вектора n раз для получения вектора распределения вероятностей.

Рассмотрев метод прогнозирования на цепях Маркова, выделим следующие особенности его применения:

- необходимо выделить состояния временного ряда. Данное действие является дополнительным и зависит от сферы применения временного ряда;

- прогнозируемый ряд должен являться Марковским процессом;
- единообразие анализа и проектирования [9].

Модель по выборке максимального подобия.

Для удобства анализа данной модели временной ряд обозначим $Z_1^N = (z_1, z_2, \ldots, z_N)$. Набор последовательных значений $Z_t^M = (z_t, z_{t+1}, \ldots, z_{t+M-1})$, лежащих внутри временного ряда Z_1^N, назовём *выборкой* из этого ряда длины $M \in [1,(N-1)]$ с моментом начала отсчёта $t \in [1,(N-M)]$. Разность начал отсчётов выборок Z_t^M и Z_{t-k}^M будем называть *задержкой* $k \in [1,(t-1)]$.

Выборки обладают свойством подобия, чем мы и воспользуемся для прогнозирования временного ряда [9]. Идея метода заключается в построении ожидаемой выборки с помощью аппроксимации уже существующей. С целью реализации данной технологии следует ответить на следующие вопросы.

1. Как аппроксимировать выборки?

Рассмотрим аппроксимацию выборки Z_{T-M+1}^M при помощи выборки $Z_{T-M+1-k}^M$ [9]. Обозначим момент времени T-M+1=t.

Вычислим аппроксимированные значения выборки $\hat{Z}_t^M$

$$\hat{Z}_t^M = \alpha_1 Z_{T-k}^M + \alpha_0 I^M$$

где $\alpha_1 и \alpha_0$ - коэффициенты, а I^M - единичный вектор размерности M.

Согласно методу наименьших квадратов, коэффициенты аппроксимации определим, исходя из уравнения

$$Z_x \cdot A = Z_y$$

где значения Z_x и Z_y определяются следующим образом:

$$Z_X = \begin{bmatrix} \sum_{i=0}^{M-1} Z^2(k+i) & \sum_{i=0}^{M-1} Z(k+i) \\ \sum_{i=0}^{M-1} Z(k+i) & M \end{bmatrix};$$

$$, Z_Y = \begin{bmatrix} \sum_{i=0}^{M-1} Z(k+i) \cdot Z(T-M+1+i) \\ \sum_{i=0}^{M-1} Z(T-M+1+i) \end{bmatrix}.$$

2. Какую выборку следует аппроксимировать?

Подходящую для аппроксимации выборку называют *базовой историей [9]*. Она располагается на оси времени сразу за *выборкой максимального подобия* для новой истории Z^{M}_{T-M+1} [9]. Новая история содержит значения процесса непосредственно перед моментом прогноза. Соответственно, чтобы вычислить базовую историю, следует определить выборку максимального подобия.

3. Как определить выборку максимального подобия для выборки новой истории?

Как следует из названия, мы ищем такую выборку, значения которой являются наиболее близкими к значениям новой истории. Отсюда, необходимо ввести меру подобия двух выборок. Введём коэффициент ρ. Он зависит от длины M выборок, а также от задержки k, и характеризует степень линейной зависимости указанных выборок: чем ближе к единице значение ρ, тем выше их линейная зависимость [9, 11].

Далее необходимо рассмотреть все возможные выборки длины M и вычислить для них коэффициент подобия новой истории. Выборка с максимальным значением ρ и будет выборкой максимального подобия. Данной выборке соответствует задежка k, которую далее обозначим как $k_{max.}$

В результате получаем функциональную зависимость значений прогнозируемой выборки Z^{P}_{t} от фактически существующей Z^{M}_{T-k} [9]:

$$\hat{Z}^{P}_{t} = \alpha_1 Z^{P}_{k_{max}+M} + \alpha_0 I^{P} = EMMSP(M)$$

На рисунке 3 приведён пример расположения рассмотренных для прогнозирования выборок.

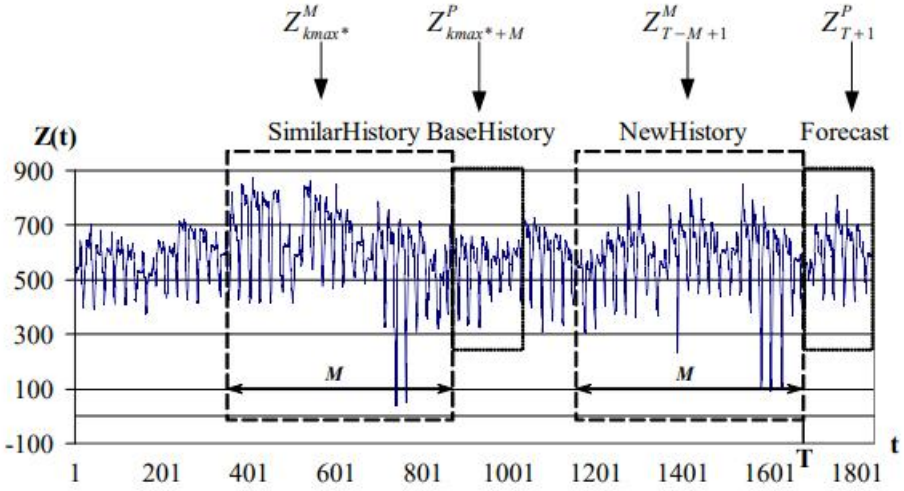


Рисунок 3. Положение выборок для прогнозирования временного ряда с помощью модели по выборке максимального подобия без учёта внешних факторов [9].

Кроме того, существует возможность построить модель, учитывающую внешние факторы, которые также представлены в виде временного ряда со значениями, соответствующими отметкам времени временного ряда Z. В данной модели отличается процесс аппроксимации выборок, в остальном алгоритм прогнозирования аналогичен уже рассмотренному.

Функциональная зависимость значений прогнозируемой выборки Z_t^P от фактически существующей Z_{T-k}^M, с учётом внешних факторов X, будет выглядеть следующим образом [9]:

$$\hat{Z}_{T+1}^P = \alpha_2 Z_{k_{max^*+M}+M}^P + \alpha_0 I^P + \alpha_1 X_{T+1}^P = EMMSP(M)$$

На рисунке 4 представлены выборки для модели с учётом внешних факторов.

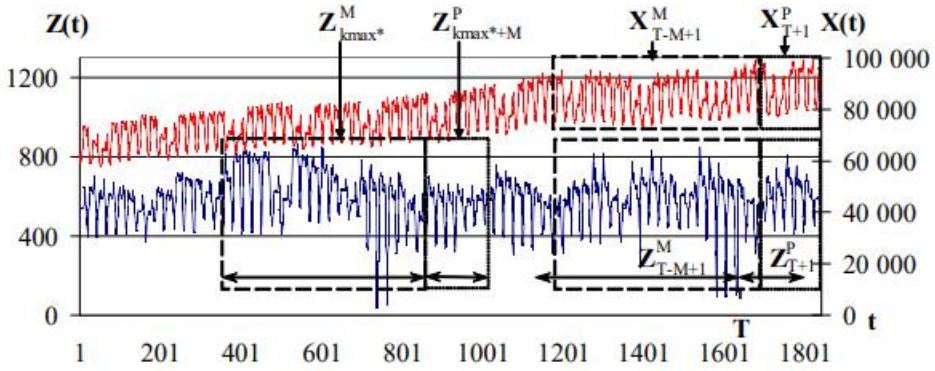


Рисунок 4. Положение выборок для прогнозирования временного ряда с помощью модели по выборке максимального подобия с учётом внешних факторов [9].

Подводя итоги, выделим основные этапы алгоритма построения модели по выборке максимального подобия.

Необходимо вычислить:

1) выборку новой истории;
2) выборку максимального подобия;
3) выборку базовой истории;
4) прогнозные значения.

Рассмотрев метод прогнозирования по выборке максимального подобия, выделим следующие особенности его применения:

- модель работает с неравноотстоящими временными рядами;

- модель применяется для стационарных и нестационарных временных рядов;
- количество итераций (1шт.) для вычисления прогноза не зависит от требуемого количества элементов прогнозируемой выборки;
- модель имеет единственный параметр M - длина выборки, от которого зависит значение прогнозируемого участка, в отличие от других авторегрессионных моделей.

Общие выводы.

Сравнительный анализ методов хранения временных рядов будет проведён во время групповой работы.

параметр\система хранения	Cassandra
Модель данных	строковая
Автоматическое удаление устаревших данных	есть
Сортировка данных по времени	есть
Сравнение скорости поступления данных и скорости обработки данных	скорость поступления данных выше
Отказоустойчивость	есть
Масштабируемость	есть

Таблица №1. Анализ системы хранения временных рядов Cassandra.

Выполнив анализ базы данных Cassandra, представляется возможным сделать вывод о том, что она удовлетворяет основным требованиям к хранилищу временных рядов.

Результаты сравнения двух методов прогнозирования временных рядов приведены в таблице №2.

параметр\метод и модель	Модель на цепях Маркова	Модель по подборке максимального подобия
Тип модели	структурная	статистическая
Необходимость преобразовывать данные временного ряда перед их прогнозированием	надо	не надо
Количество итераций или раз применения	n раз для прогнозирования n	одна итерация. Однако перед этим проводится

некоторой формулы для получения прогноза	состояний	аппроксимация Т-М-1 выборок длины М.
Область применения	Применимо к временным рядам, выполняющим Марковское свойство. Неприменимо к долгохранимым временным рядам	Неравностоящие, стационарные и нестационарные ряды
Количество параметров, влияющих на результат, задаваемых пользователем	0	1 - длина выборки М

Таблица №2. Сравнения двух методов прогнозирования временных рядов на модели по выборке максимального подобия и Модели на Марковских цепях.

Анализ представленных в таблице данных позволяет сделать следующие выводы:

- область применения методов построения модели на Марковских цепях и модели по выборке максимального подобия различны: в некоторых ситуациях можно использовать первую модель, в то время как вторая будет неприменима и наоборот;
- Метод на Марковских цепях требует дополнительных проверок перед его применением;
- модель на Марковских цепях требует анализа временных рядов и их преобразования - выделения состояний;
- количество необходимых вычислений для прогнозирования временных рядов варьируется. Для краткосрочных прогнозов использование модели на Марковских цепях предпочтительнее, так как количество итераций (перемножений матрицы и вектора) будет равно количеству прогнозируемых состояний, в то время как в модели по выборке максимального подобия количество итераций будет равно Т-М-1, где Т - количество значений временного ряда, а М - длина выборки.

Используемая литература.

1. https://elibrary.ru/download/elibrary_53949324_87954537.pdf - Белоусова Е.Е., Ракитский А.А. Особенности применения методов на основе марковских цепей для прогнозирования временных рядов
2. kizbikenov.pdf (altspu.ru) - К.О. Кизбикенов «Прогнозирование и временные ряды»
3. Джефф Карпентер, Эбен Хьюитт «Cassandra. Полное руководство»
4. Репликация SQL Server - SQL Server | Microsoft Learn
5. http://pzs.dstu.dp.ua/DataMining/times/bibl/time-series0.pdf - Д.Е. Намиот «Базы данных временных рядов и средства обработки»
6. МАСШТАБИРУЕМЫЕ РАСПРЕДЕЛЕННЫЕ ХРАНИЛИЩА. CASSANDRA ИЛИ HBASE? (cyberleninka.ru)
7. part.pdf (williamspublishing.com)- «Хранение временных рядов»
8. 1-2_Soder.indd (elibrary.ru) - Е.М. Бронштейн, А.И. Авзалова «Прогнозирование цены акции на основе свойств цепей Маркова»
9. Чучуева Ирина Александровна «Модель прогнозирования временных рядов по выборке максимального подобия»
10. https://www.elibrary.ru/download/elibrary_24669862_36850259.pdf - Мамаев К.Л., Тутубалин П.П. «Прогнозирование будущих отчетных периодов на основе временных рядов» (использование модели по выборке максимального подобия)
11. https://cyberleninka.ru/article/n/prognozirovanie-urovnya-glyukozy-v-krovi-bolnyh-insulinozavisimym-diabetom-neyronnymi-setyami-i-metodom-ekstrapolyatsii-po-vyborke/viewer - «Прогнозирование уровня глюкозы в крови больных инсулинозависимым диабетом нейронными сетями и методом экстраполяции по выборке максимального подобия» Чернецов С. А., Чучуева И. А.
12. https://unitech-mo.ru/upload/files/science/information-technology-journal/itv03_2017.pdf#page=118 - «Методы прогнозирования на основе анализа временных рядов» Н.П. Сидорова, Д.С. Демина (использование модели по выборке максимального подобия)
13. https://www.elibrary.ru/download/elibrary_48124652_55808541.pdf#page=105 - А.А. Мальцева «Модель прогнозирования для таргетированной рекламы на основе цепей Маркова»
14. Полуденный эффект во временных рядах землетрясений и сейсмического шума (elibrary.ru) - «Полуденный эффект во временных рядах землетрясений и сейсмического шума» Сидорин А.Я.
15. ПРИМЕНЕНИЕ МЕТОДОВ И МОДЕЛЕЙ ПРОГНОЗИРОВАНИЯ ВРЕМЕННЫХ РЯДОВ ДЛЯ ОЦЕНКИ ЦИКЛИЧЕСКОЙ НАГРУЗКИ В ОБЛАЧНЫХ СИСТЕМАХ (elibrary.ru)–

«Применение методов и моделей прогнозирования временных рядов для оценки циклической нагрузки в облачных системах» Логунов Д.Г.

16. Цепи Маркова в НЛП - GeeksforGeeks - пример использования для моделирования естественного языка.

17. https://elibrary.ru/download/elibrary_44801640_58060738.pdf - «Обзор моделей прогнозирования временных рядов» Осмонканов А.М., Абдиева Л.К., Курманбекова А.К.

18. tsifrovaya-kriminologiya-matematicheskie-metody-prognozirovaniya-chast-1.pdf - статья про прогнозирование в криминологии.