Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение высшего образования
«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ «ИНФОРМАТИКА И СИСТЕМЫ УПРАВЛЕНИЯ» (ИУ)

КАФЕДРА «ПРОГРАММНОЕ ОБЕСПЕЧЕНИЕ ЭВМ И ИНФОРМАЦИОННЫЕ ТЕХНОЛОГИИ» (ИУ7)

РАСЧЕТНО-ПОЯСНИТЕЛЬНАЯ ЗАПИСКА

К НАУЧНО-ИССЛЕДОВАТЕЛЬСКОЙ РАБОТЕ

НА ТЕМУ:

Методы хранения и прогнозирования временных рядов

Студент **ИУ7-51Б** _____ **Вылегжанина А. И.**

Студент **ИУ7-56Б** _____ **Жаворонкова А. А.**

Студент **ИУ7-51Б** _____ **Косицкая П. А.**

Руководитель _____ **Кострицкий А. С.**

2023 г.

Содержание

ВВЕДЕНИЕ **3**

1 Методы хранения **5**

1.1 Хранение временных рядов в OpenTSDB 6

1.2 Хранение временных рядов в Cassandra 7

1.3 Хранение временных рядов в файлах 9

1.4 Сравнение методов хранения временных рядов 10

2 Методы прогнозирования **13**

2.1 Модель экспоненциального сглаживания 14

2.2 Регрессионная модель 15

2.3 Авторегрессионные модели прогнозирования 17

2.4 Модель на классификационно – регрессионных деревьях CART 23

2.5 Модель на цепях Маркова 25

2.6 Сравнение методов прогнозирования временных рядов . . . 28

ЗАКЛЮЧЕНИЕ **32**

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ **34**

ВВЕДЕНИЕ

В философском смысле сама жизнь – это движение, то есть процесс. Мы включены в разнообразные процессы: изменение уровня глюкозы в крови, появление солнечных пятен, рост цен акций и многие другие. Независимо от того являемся ли мы их источником, участником или просто подвержены влиянию этих процессов, нам требуются технологии наблюдения, анализа и прогнозирования явлений, описываемых большим объемом информации.

Задачи воспроизведения источника информации с целью анализа данных, поиска основных закономерностей и структур, а также прогнозирования возможных будущих значений решается посредством использования временных рядов [1].

Временной ряд – это последовательность числовых значений, упорядоченных по времени, отражающих характер изменений в определенном процессе или явлении [2]. Элементы временного ряда включают в себя два обязательных параметра: отметку времени и значение показателя ряда, соответствующее указанной отметке времени [3]. Далее будем обозначать временной ряд $Z(t)$, где t – временной отрезок а z – значение.

Область применения временных рядов охватывает различные сферы: экономику [4, 5, 6, 7], биологию [8], сейсмологию [9], программирование [10], медицинскую диагностику [11] (например, данные ЭКГ и ЭЭГ пациента) и так далее.

На рисунке 1 представлен пример временного ряда цен на электроэнергию европейской территории РФ.

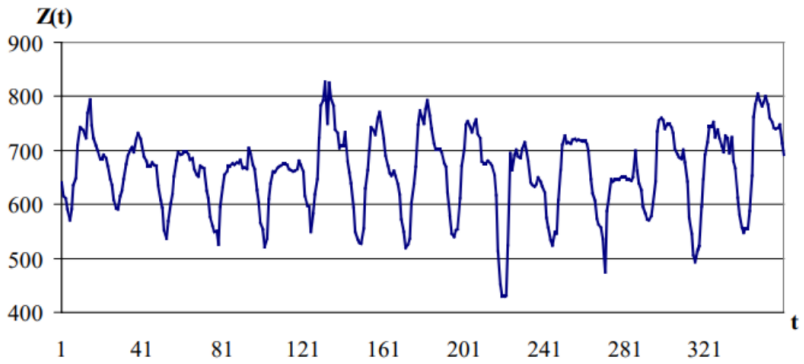


Рисунок 1 – Временной ряда цен на электроэнергию европейской территории РФ (в условных денежных единицах) [3]

Временные ряды дают возможность предугадать динамику отслеживаемых процессов. Прогноз основывается на данных, которые фиксируются на протяжении некоторого времени, что требует организации их хранения.

Целью данной научно-исследовательской работы является классификация методов хранения и прогнозирования временных рядов.

Для достижения поставленной цели требуется выполнить следующие задачи:

— провести анализ предметной области «временные ряды»;

— описать основные подходы к решению задачи прогнозирования и хранения временных рядов;

— сформулировать критерии сравнения методов;

— выполнить классификацию методов.

1 Методы хранения

Необходимым условием для работы с временными рядами является организация хранения отслеживаемых данных.

В силу особенностей временных рядов и их обработки обозначим ключевые требования к средствам их хранения:

— приоритетность скорости записи данных перед скоростью их обработки, так как операции записи преобладают над операциями чтения [12];

— упорядоченность хранимых данных по времени, так как данные записываются, считываются и обновляются не случайным образом, а во временном порядке [12];

— расширяемость и вместительность хранилища данных;

— гарантия сохранности данных.

В данной работе в качестве методов хранения выделим и рассмотрим следующие подходы:

— использование баз данных, специализированных для временных рядов – OpenTSDB;

— использование нереляционных БД – Cassandra;

— использование файлов.

OpenTSDB — технология специализированная для временных рядов, поэтому стоит уделить ей особое внимание, так как это позволит выявить основные черты специализированных для временных рядов БД.

Нереляционная база данных является более универсальной технологией. В качестве представителя данного класса, рассмотрим Cassandra, так как она наиболее востребована среди подобных.

По своей сути, база данных — это файл, обернутый в специальное программное обеспечение, которое делает его максимально безопасным в использовании. Иногда имеет смысл отказаться от оболочки и работать с данными напрямую. Рассматривая данный подход, обратимся к методу использованию файлов.

1.1 Хранение временных рядов в OpenTSDB

При работе с динамическими временными рядами основной задачей является эффективная организация данных. Поскольку временные ряды обновляются и пополняются новыми значениями, требуются оптимизированные структуры данных для быстрого доступа к информации и эффективного выполнения запросов. Кроме того, база данных должна обеспечивать быструю и эффективную запись новых данных.

OpenTSDB (Open Time Series Database) обеспечивает хранение и агрегацию временных рядов для обеспечения масштабируемости и производительности при работе с большими объемами данных. В OpenTSDB элемент временного ряда состоит из вещественного значения, уникального идентификатора временного ряда, метки времени и набора тегов. Теги представляют собой символьные строки для хранения метаданных.

OpenTSDB предоставляет возможности для индексирования данных и агрегации по времени и меткам. Это позволяет эффективно выполнять запросы к большим наборам данных временных рядов, выполнять аналитику и получать агрегированные результаты. Данная база данных разработана с учетом горизонтального масштабирования, что позволяет легко добавлять новые узлы для увеличения общей емкости хранения и производительности.

В OpenTSDB запросы к базе данных формируются с использованием языка JSON [13]. Эти запросы поддерживают различные операции, такие как арифметические и логические выражения, фильтры, группировка, статистические и аналитические функции. Одной из таких функций является линейная интерполяция. Если недостаточно реальных данных для интерполяции, то результатом может быть значение «NaN». Также в OpenTSDB существуют запросы по временному диапазону, фильтрация по меткам, позволяющая выбирать временные ряды с определенными значениями метаданных, агрегация, с помощью которой есть возможность вычислить среднее значение, сумму или других статистических показателей для временных рядов.

OpenTSDB не предоставляет инструменты для интеллектуального анализа временных рядов, за исключением линейной интерполяции, но допускает расширения от сторонних разработчиков, добавляющие указанную

функциональность (например, библиотека R2Time [14], реализованная на языке программирования R).

1.2 Хранение временных рядов в Cassandra

Apache Cassandra — базы данных, которая является:

— *распределенной* — обеспечивает работу на нескольких машинах, в дальнейшем называемых узлами, которые пользователем представляются как единое целое [15];

— *децентрализованной* — все узлы являются равноправными [15];

— *эластично масштабируемой* — обеспечивает возможность добавлять и убирать узлы, не прерывая работы системы. Данное свойство является специальным для горизонтальной масштабируемости — механического увеличения пропускной способности оборудования путум добавления памяти в уже имеющуюся машину [15];

— *отказоустойчивой* — предполагает замену поврежднных узлов без простоя, за счут их репликации на несколько узлов [15] (репликация представляет собой набор технологий копирования и распространения данных и объектов между узлами, а также включает синхронизацию этих узлов для поддержания их согласованности (согласованность означает, что операция чтения всегда возвращает последнее записанное значение) [15, 16]);

— *допускающей настройку согласованности* — существует возможность настроить количество узлов, которые должны подтвердить завершение операции обновления данных [15].

Основными структурами данных в Cassandra являются:

— *столбец* — пара имя-значение;

— *строка* — контейнер для упорядоченной коллекции столбцов на которые можно сослаться по первичному ключу;

— *таблица* — контейнер для упорядоченной коллекции строк;

— *пространство ключей* — контейнер таблиц;

— *кластер* — контейнер пространств ключей, расположенных в одном или нескольких узлах [15].

Таким образом, столбец — самая элементарная структурная единица в модели данных Cassandra, и ему присущи следующие характеристики: имя; значение; тип; временная метка, генерируемая при каждом обновлении столбца; время жизни, указывающее срок хранения значения столбца [15].

Уточнив основные понятия базы данных, рассмотрим особенности Cassandra применительно к хранению временных рядов.

Модель данных организует хранение временного ряда, где *ключ для строки* — имя для нашего измерения, *имя столбца* — время измерения, *значение столбца* — измеренное значение [17]. Данная структура позволяет выбрать как индивидуальное значение, так и набор значений для заданного интервала какого-либо измерения [17].

Кроме того, для каждого столбца хранится время жизни, позволяющее автоматизировать процесс удаления устаревших данных, а также временная метка, которая используется с целью:

— разрешения конфликтов при изменении одного и того же значения со стороны нескольких клиентов [15],

— организации автоматической сортировки данных по времени [17].

В случае обработки временных рядов скорость поступления данных имеет большее значение, нежели скорость их изменения, потому что информация однородна и фактически обрабатывается только небольшая часть из всего объума хранимой информации [17]. Данные особенности позволяют выделить Cassandra, как нереляционную БД (скорость добавления данных в NoSQL системах выше, чем в SQL системах) [17]. Cassandra является распределунной и децентрализованной, вследствие этого можно выделить следующие еу аспекты:

— отказоустойчивость — гарантия сохранности информации за счут репликации [18];

— масштабируемость — увеличение объума хранимых данных возможно посредством добавления узла в кластер [18];

— слабая согласованность данных — отсутствие контроля актуальности читаемой информации [15]. Данная особенность может быть скорректирована настройкой согласованности.

1.3 Хранение временных рядов в файлах

Временные ряды могут храниться в текстовых, CSV и JSON файлах. В данном случае все взаимодействия с данными, а именно распределение памяти для хранения данных, открытие, чтение и закрытие файлов, их защита и так далее, выполняются специалистом по анализу данных «вручную».

Преимущества данного способа, по сравнению с использованием баз данных, следующие [12]:

— не требует значительных временных затрат на ввод/вывод данных, так как данная операция производится посредством чтения/изменения файла;

— существует возможность максимально увеличить сжатие данных, что позволяет сократить требуемый объем памяти для хранения временного ряда;

— обеспечивает хранение различных типов временных рядов, включая данные с разной частотой и разрешением;

— используется для обмена данными между различными системами;

— применяется для резервного копирования данных.

Недостатками данного способа, по сравнению с использованием баз данных, являются [12]:

— снижение производительности при увеличении объума хранимых данных;

— отсутствие возможности масштабировать систему хранения;

— уязвимость системы к несанкционированным доступам и изменениям;

— отсутствие эффективной организации работы с данными при увеличении количества пользователей;

— необходимость обеспечивать и поддерживать структуру и целостность данных.

1.4 Сравнение методов хранения временных рядов

Результаты классификации методов хранения временных рядов приведены в таблице 1.1.

Таблица 1.1 – Классификация методов хранения временных рядов

Параметр	Система хранения		
	Cassandra	OpenTSDB	файлы
автоматическое удаление устаревших данных	есть	нет	нет
автоматическая сортировка данных по времени	есть	нет	нет
сравнение скорости поступления и обработки данных	скорость поступления данных выше	скорость поступления данных выше [19]	скорость поступления и обработки данных не имеет значительных различий
отказоустойчивость	есть	есть	нет
масштабируемость	гибкая масштабируемость	горизонтальная масштабируемость [20]	нет
инструменты для интеллектуального анализа временных рядов	нет	линейная интерполяция, допускаются расширения от сторонних разработчиков	нет
возможность сократить объум требуемой памяти	нет	нет	есть
встроенный модуль для визуализации данных	нет	есть встроенный инструмент построения линейных графов на основе нескольких метрик и меток [20]	нет
составляющие единицы данных	временная метка, значение, время жизни	любое количество значений, временная метка	значение

В силу того, что OpenTSDB является надстройкой над некоторой базой данных, в том числе и Cassandra [21], становится очевидным его преимущество перед ней в возможности автоматизированного интеллектуального анализа временных рядов, визуализации данных и т. п.. Однако, автоматизация сортировки данных по времени и удаления устаревшей информации характерна только для Cassandra. С другой стороны, в OpenTSDB возможно хранить несколько значений для одной временной метки.

Несмотря на большое количество недостатков файловой организации по сравнению с базами данных, стоит отметить некоторые их особые области применения: обмен данными между различными системами и резервное копирование. Возможность максимально сжать информацию делает предложенный метод, применительно к конкретным задачам, конкурентным по отношению к базам данных, при этом сохраняется перспектива использования файлов совместно с БД.

Таким образом, в работе были рассмотрены три различных подхода к хранению временных рядов, выделены особенности их использования, на примере одного из представителей каждого вида и проведена классификация методов по параметрам, определунных требованиями к хранению временных рядов.

2 Методы прогнозирования

Под прогнозированием, в широком смысле, понимают вероятностное предположение о состоянии определенного явления в будущем, основанное на специальном научном исследовании [22]. Необходимо различать два взаимосвязанных понятия – метод прогнозирования и модель прогнозирования.

Метод прогнозирования представляет собой последовательность действий, которые нужно совершить для получения модели прогнозирования временного ряда [6].

Модель прогнозирования есть представление зависимости будущего значения от прошлого [3, 7], при этом способ задания этой зависимости может быть различным. В некоторых моделях учитывается влияние внешних факторов — процессов, протекающих параллельно с исследуемым и влияющих на него. Внешние факторы могут быть дискретными (представленными временными рядами) или категориальными (представленными множеством групп) [3, 23, 24], при работе с которыми определяют принадлежность значения временного ряда к одной из групп. Далее в работе будем обозначать внешние факторы как $X(t)$.

В соответствии со способом задания зависимости между будущими и фактическими значениями временного ряда, а также внешними факторами выделяют следующие виды моделей: статистические и структурные.

В *статистических* моделях данная зависимость *задана аналитически* [3].

К статистическим относятся следующие группы моделей:

— регрессионные;

— авторегрессионные;

— экспоненциального сглаживания [3].

В *структурных* моделях зависимость будущего значения от прошлого задается в виде некоторой *структуры* и правил *перехода* по ней [3, 7].

К структурным относятся следующие группы моделей:

— нейросетевые;

— на базе цепей Маркова;

— на базе классификационно – регрессионных деревьев [3].

Необходимо отметить, что названия моделей и соответствующих методов как правило совпадают [3].

На основе полученных и хранимых данных прогнозируется дальнейшее поведение временных рядов.

В нашей работе будут рассмотрены следующие методы:

— модель экспоненциального сглаживания;

— модель на цепях Маркова;

— регрессионная модель:

  – простая линейная регрессия;

  – множественная регрессия;

  – нелинейная регрессия;

— авторегрессионные модели:

  – ARIMAX;

  – GARCH;

  – ARDLM;

  – модель по выборке максимального подобия;

— модель на классификационно – регрессионных деревьях(CART) [3].

2.1 Модель экспоненциального сглаживания

Для того, чтобы прогнозирующая система, включающая тот или иной математический аппарат, могла автоматически распознавать изменения параметров модели, используется метод экспоненциального сглаживания.

С этой целью применяется сглаженная функция наблюдений:

$$\hat{z}_t = a \cdot z_t + (1 - a) \cdot \widehat{z}_{t-1}. \tag{2.1}$$

Операция (2.1), выполняемая при каждом новом наблюдении, называется экспоненциальным сглаживанием. Значение a, которое примерно равно $1/n$, называется коэффициентом сглаживания. Поскольку операция (2.1) проводится одинаково для всех значений ряда динамики, мы можем выразить учет более ранних значений в виде:

$$\begin{aligned}\hat{z}_t &= a \cdot z_t + (1-a) \cdot (a \cdot z_{t-1} + (1-a) \cdot \widehat{z}_{t-1}) = \\ &= a \cdot z_t + (1-a) \cdot (a \cdot z_{t-1} + (1-a) \cdot (a \cdot z_{t-2} + (1-a) \cdot \widehat{z}_{t-3})) = \\ &= \ldots = a \cdot \sum_{k=1}^{t-1} (1-a)^k \cdot z_{t-k} + (1-a)^t \cdot z_0. \quad (2.2)\end{aligned}$$

Таким образом, сглаженное значение $\hat{z}_t$ представляет собой линейную комбинацию всех значений ряда динамики, при этом их веса уменьшаются по геометрической прогрессии со временем.

2.2 Регрессионная модель

Регрессионная модель базируется на концепции регрессии, которая представляет собой статистическую зависимость математического ожидания одной случайной величины от значений другой или нескольких случайных величин. Основная цель при построении регрессионной модели заключается в обнаружении связи между исходной переменной и несколькими регрессорами (факторами). В данной работе будут рассмотрены следующие виды регрессионных моделей:

— простая линейная регрессия;

— множественная регрессия;

— нелинейная регрессия.

2.2.1 Простая линейная регрессия

Модель основана на предположении о существовании дискретного внешнего фактора $X(t)$, который влияет на рассматриваемый процесс $Z(t)$, и связь между этим фактором и процессом описывается в виде линейной функции. Уравнение для модели прогнозирования временного ряда на ос-

нове линейной регрессии представляет собой:

$$Z(t) = a_0 + a_1 \cdot X(t) + \varepsilon_t, \tag{2.3}$$

где a_0, a_1 — коэффициенты регрессии; ε_t — ошибка модели.

Классический метод оценки коэффициентов линейной регрессии строится на методе наименьших квадратов. Этот метод позволяет найти значения коэффициентов a_0 и a_1, при которых сумма квадратов разностей между фактическими значениями Z и предсказанными значениями Z_t будет минимальной, то есть:

$$\sum_{i=1}^{n}(Z_i - Z_{t_i})^2 = \sum_{i=1}^{n}\varepsilon_i^2 \to \min \tag{2.4}$$

2.2.2 Множественная регрессия

Для прогнозирования значений процесса $Z(t)$ в момент времени t необходимо иметь значение $X(t)$ для того же времени, что в реальности часто бывает сложно. На практике процесс $Z(t)$ может зависеть от множества дискретных внешних факторов $X1(t), \ldots, Xs(t)$. Таким образом, модель прогнозирования принимает следующий вид:

$$Z(t) = a_0 + a_1 \cdot X_1(t) + a_2 \cdot X_2(t) + \ldots + a_s \cdot X_s(t) + \varepsilon_t, \tag{2.5}$$

$a_0, a_1, \ldots, a_s$ — коэффициенты регрессии; ε_t — ошибка модели.

Коэффициенты регрессии также определяются с использованием метода наименьших квадратов, но в этом случае решается система нормальных уравнений, определитель которой выглядит как:

$$\begin{vmatrix} n & \sum X_1 & \ldots & \sum X_s^2 \\ \sum X_1 & \sum X_1^2 & \ldots & \sum X_1 X_s \\ \ldots & \ldots & \ldots & \ldots \\ \sum X_s & \sum X_1 X_s & \ldots & \sum X_s^2 \end{vmatrix} \tag{2.6}$$

2.2.3 Нелинейная регрессия

Нелинейная модель предполагает существование определенной функции:

$$Z(t) = F(X(t), A), \tag{2.7}$$

где $Z(t)$ — исходный процесс; $X(t)$ — внешний фактор, от которого зависит процесс $Z(t)$; A — функция, параметры которой необходимо определить в рамках построения модели прогнозирования.

На практике нелинейные регрессионные модели применяются редко, поскольку лишь небольшая часть процессов имеет известную заранее функциональную зависимость [25].

2.3 Авторегрессионные модели прогнозирования

2.3.1 Модель прогнозирования ARIMAX

1. Авторегрессия p-го порядка $AR(p)$ — это модель временного ряда, в которой его прогнозируемое значение является линейной комбинацией конечного числа предыдущих значений этого ряда и белого шума [3, 26].

$$Z(t) = \sum_{i=1}^{p} \alpha_i \cdot Z_{t-i} + \epsilon_t, \tag{2.8}$$

где p — число значений ряда, учитываемых в модели (порядок модели); α_i — коэффициенты модели, их требуется оценить при построении; ϵ_t — белый шум — случайная составляющая, которая не может быть объяснена предыдущими значениями временного ряда и используется для оценки точности прогнозов [26].

2. Модель скользящего среднего q-го порядка $MA(q)$ — модель временного ряда, в которой его прогнозируемое значение является линейной комбинацией конечного числа предыдущих значений белого шума [27, 26].

$$Z(t) = \epsilon_t + \sum_{j=1}^{q} b_j \cdot \epsilon_{t-j}, \tag{2.9}$$

где b_j — параметры модели; ϵ — белый шум.

3. $ARMA(p, q)$ модель включает в себя авторегрессию p-го порядка

$AR(p)$ и модель скользящего среднего q-го порядка $MA(q)$ [3, 26]. 4. При **ARIMA** требуется произвести следующие действия [3]:

1) выявить наличие единичных корней;

2) определить порядок интегрированности временного ряда;

3) если порядок интегрированности больше нуля:

   3.1) преобразовать ряд взятием разности (обычно равна значению белого шума) соответствующего порядка;

   3.2) построить ARMA-модель для преобразованной стационарной модели.

Модель прогнозирования ARIMAX (AutoRegressive Integrated Moving Average eXtended) — это математическая модель для анализа временных рядов, объединяющая в себе интегрированную авторегрессию, скользящее среднее и возможность учета внешних факторов (exogenous factors) [3, 26].

2.3.2 Модель прогнозирования GARCH

Прогнозирование с использованием авторегрессионной модели с условной гетероскедастичностью (GARCH) происходит следующим образом [3, 26]:

1) определить модель $AR(p)$ для исходного временного ряда (2.8);

2) взять ошибку (белый шум) модели (2.8) ϵ_t равным:

$$\epsilon_t = \sigma_t \cdot v_t, \tag{2.10}$$

где σ_t — зависимое от времени стандартное отклонение; v_t — величина, с нормальным распределением, среднее значение равно 0, и стандартное отклонение равно 1.

$$\sigma_t^2 = b_0 + b_1 \cdot \epsilon_{t-1}^2 + \ldots + b_q \cdot \epsilon_{t-q}^2 + c_1 \cdot \sigma_{t-1}^2 + \ldots + c_p \cdot \sigma_{t-p}^2, \tag{2.11}$$

где b_i и c_i — коэффициенты.

Уравнение (2.11) называется моделью $GARCH(p, q)$. p – характеризует порядок авторегрессии квадратов остатков; q — количество предшествующих оценок остатков [3, 26].

2.3.3 Модель прогнозирования ARDLM

При моделировании процессов на изучаемую переменную могут влиять не только текущие значения процесса, но и его лаги, то есть значения временного ряда, предшествующие изучаемому моменту времени [3, 26]. Например, для переменной z_t лагом в k периодов будет z_{t-k}.

При работе с временными рядами удобно использовать лаговый оператор L–оператор сдвига назад во времени [26]:

$$L^m \cdot z_t = z_{t-m}, \tag{2.12}$$

где m — количество периодов задержки (величина лага).

Модель авторегрессии распределенного лага ARDLM(p,l) описывается уравнением [26]:

$$Z(t) = \varphi_0 + \varphi_1 Z(t - l - 1) + \ldots + \varphi_p Z(t - l - p) + \epsilon_t, \tag{2.13}$$

где φ_i — количество периодов задержки (величина лага); ϵ_t — белый шум; l — величина лага.

2.3.4 Модель по выборке максимального подобия EMMSP

Для удобства анализа данной модели временной ряд обозначим как $Z_1^N = (z_1, z_2, \ldots, z_N)$. Набор из M последовательных значений $Z_t^M = (z_t, z_{t+1}, \ldots, z_{t+M-1})$, лежащих внутри временного ряда Z_1^N, назовем *выборкой* из этого ряда длины $M \in [1, (N-1)]$ с моментом начала отсчета $t \in [1, (N-M)]$. Разность начал отсчетов выборок Z_t^M и Z_{t-k}^M будем называть *задержкой* $k \in [1, (t-1)]$.

Выборки обладают свойством подобия, чем мы и воспользуемся для прогнозирования временного ряда [3]. Идея метода заключается в построении ожидаемой выборки с помощью аппроксимации уже существующей.

С целью реализации данной технологии следует ответить на следующие вопросы.

1. Как аппроксимировать выборки?

Рассмотрим аппроксимацию выборки
Z^M_{T-M+1} при помощи выборки $Z^M_{T-M+1-k}$ [3]. Обозначим момент времени $T - M + 1 = t$.

Вычислим аппроксимированные значения выборки $\widehat{Z}^M_t$:

$$\widehat{Z}^M_t = \alpha_1 Z^M_{T-k} + \alpha_0 I^M, \tag{2.14}$$

где α_1 и α_0 — коэффициенты, а I^M - единичный вектор размерности M.

Согласно методу наименьших квадратов, коэффициенты аппроксимации определим, исходя из уравнения

$$Z_x \cdot A = Z_y, \tag{2.15}$$

где Z_x и Z_y определяются следующим образом:

$$Z_X = \begin{pmatrix} \sum_{i=0}^{M-1} Z^2(k+1) & \sum_{i=0}^{M-1} Z(k+i) \\ \sum_{i=0}^{M-1} Z(k+1) & M \end{pmatrix};$$

$$\mathrm{Z}_Y = \begin{pmatrix} \sum_{i=0}^{M-1} Z(k+i) \cdot Z(T-M+1+i) \\ \sum_{i=0}^{M-1} Z(T-M+1+i) \end{pmatrix}. \tag{2.16}$$

2. Какую выборку следует аппроксимировать?

Подходящую для аппроксимации выборку называют *базовой историей* [3]. Она располагается на оси времени сразу за *выборкой максимального подобия* для новой истории Z^M_{T-M+1} [3]. Новая история содержит значения процесса непосредственно перед моментом прогноза. Соответственно, чтобы вычислить базовую историю, следует определить выборку максимального подобия.

3. Как определить выборку максимального подобия для выборки новой истории?

Как следует из названия, мы ищем такую выборку, значения которой являются наиболее близкими к значениям новой истории. Отсюда, необхо-

димо ввести меру подобия двух выборок. Введем коэффициент ρ. Он зависит от длины M выборок, а также от задержки k, и характеризует степень линейной зависимости указанных выборок: чем ближе к единице значение ρ, тем выше их линейная зависимость [3, 8].

Далее необходимо рассмотреть все возможные выборки длины M и вычислить для них коэффициент подобия новой истории. Выборка с максимальным значением ρ и будет выборкой максимального подобия. Данной выборке соответствует задержка k, которую далее обозначим как $kmax$.

В результате получаем функциональную зависимость значений прогнозируемой выборки Z_t^P от фактически существующей Z_{T-k}^M [3]:

$$\widehat{Z}_t^P = \alpha_1 Z_{k_{max}+M}^P + \alpha_0 I^P = EMMSP(M), \tag{2.17}$$

На рисунке 2.1 приведен пример расположения рассмотренных для прогнозирования выборок.

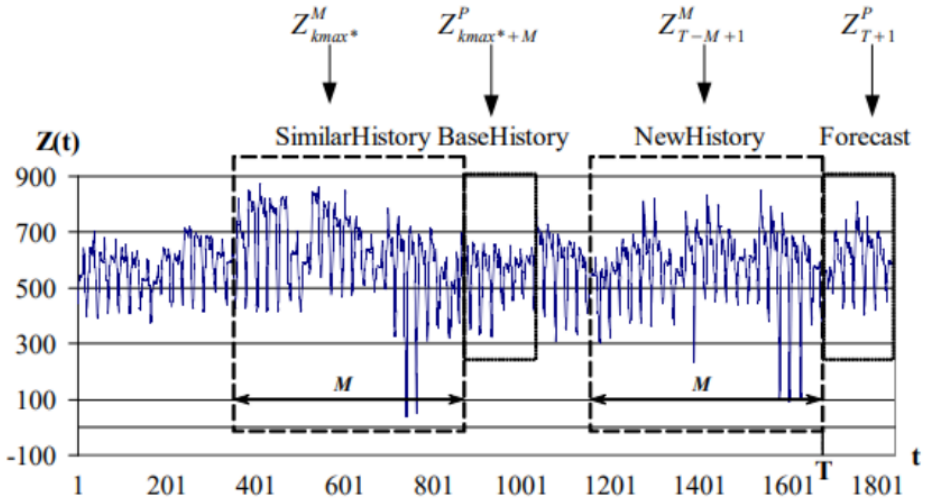


Рисунок 2.1 – Положение выборок для прогнозирования временного ряда с помощью модели по выборке максимального подобия без учета внешних факторов [3]

Кроме того, существует возможность построить модель, учитывающую внешние факторы, которые также представлены в виде временного ряда со значениями, соответствующими отметкам времени временного ряда Z. В данной модели отличается процесс аппроксимации выборок, в остальном алгоритм прогнозирования аналогичен уже рассмотренному.

Функциональная зависимость значений прогнозируемой выборки Z_t^P от фактически существующей Z_{T-k}^M, с учетом внешних факторов X, будет

выглядеть следующим образом [3]:

$$\widehat{Z}^P_{T+1} = \alpha_2 Z^P_{k_{max^*+M}+M} + \alpha_0 I^P + \alpha_1 X^P_{T+1} = EMMSP(M), \qquad (2.18)$$

На рисунке 2.2 представлены выборки для модели с учетом внешних факторов.

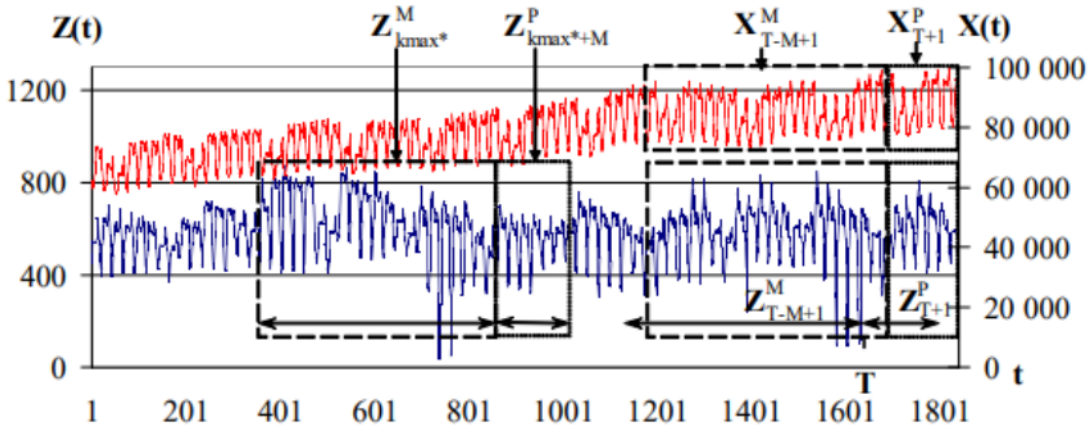


Рисунок 2.2 – Положение выборок для прогнозирования временного ряда с помощью модели по выборке максимального подобия с учетом внешних факторов [3]

Подводя итоги, можно выделить основные этапы алгоритма построения модели по выборке максимального подобия.

Необходимо вычислить:

1) выборку новой истории;

2) выборку максимального подобия;

3) выборку базовой истории;

4) прогнозные значения.

Рассмотрев метод прогнозирования по выборке максимального подобия, можно выделить следующие особенности его применения:

— модель работает с неравноотстоящими временными рядами;

— модель применяется для стационарных и нестационарных временных рядов;

— количество итераций (1шт.) для вычисления прогноза не зависит от требуемого количества элементов прогнозируемой выборки;

— модель имеет единственный параметр M — длина выборки, от которого зависит значение прогнозируемого участка, в отличие от других авторегрессионных моделей.

2.4 Модель на классификационно – регрессионных деревьях CART

Структурные модели CART разработаны для моделирования процессов, на которые оказывают влияние как дискретные внешние факторы, так и категориальные. Если внешние факторы, влияющие на процесс $X(t)$, дискретны, то используются регрессионные деревья; если факторы категориальные, то – классификационные деревья. В случае, если необходимо учитывать факторы обоих типов, то используются смешанные классификационно – регрессионные деревья [3, 28].

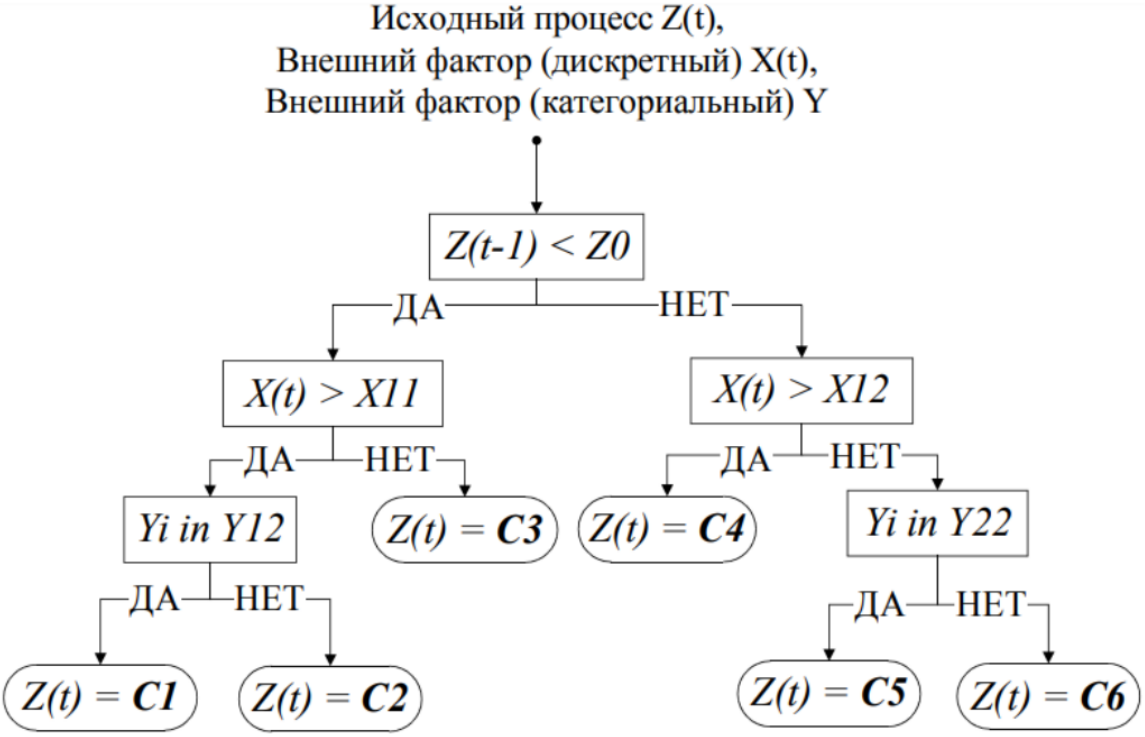


Рисунок 2.3 – Бинарное классификационно – регрессионное дерево

Согласно модели CART, прогнозное значение временного ряда зависит от предыдущих значений, а также некоторых независимых переменных.

На рисунке 2.3 рассматривается пример классификационно – регрессионного дерева, прогнозирование по такому дереву протекает следующим образом:

1) предыдущее значение процесса сравнивается с константой X_0;

2) если $Z(t-1) < Z_0$, то

   2.1) если $X(t)_{11}$, то $Z(t) = C_3$, иначе

      2.1.1) если Y_{i12}, то $Z(t) = C_3$, иначе $Z(t) = C_2$;

   иначе

   2.2) если $X(t) > X_{12}$, то $Z(t) = C_4$, иначе

      2.2.1) если Y_{i22}, то $Z(t) = C_5$, иначе $Z(t) = C_6$.

При определении значения учитываются как дискретные внешние факторы $X(t)$, так и категориальные Y, для которых выполняется проверка принадлежности значения в одном из заранее определенных подмножеств.

Значения пороговых констант, Z_0, X_{11}, а также подмножеств Y_{12}, Y_{22} определяются на этапе построения дерева.

Таким образом был описан метод прогнозирования временного ряда посредством классификационно – регрессионных деревьев. Для использования этого метода необходимо указать алгоритм построения бинарного дерева решений (дихотомической классификационной модели) — CART (Classification and Regression Tree). Его суть заключается в рекурсивном делении исходного набора данных на подмножества, которые становятся все более и более однородными относительно выделенных признаков, в результате чего формируется древовидная иерархическая структура, где каждый узел дерева имеет только двух потомков [28, 29, 30, 31].

Построение дерева происходит следующим образом [28, 29, 30, 31]:

1) выборать атрибут, который должен разбить множество наблюдений в узле так, чтобы результирующие подмножества содержали элементы, принадлежащие одному классу или количество «примесей» было минимально.

2) оценить правильность выбора атрибута разбиения используется индекс Джини, лучшим будет то разбиение, для которого значение индекса Джини будет минимальным. Индекс рассчитывается по формуле:

$$Gini(Q) = 1 - \sum_{i=1}^{n} p_i^2, \tag{2.19}$$

где Q — результирующее множество; n — число классов в нем; $p_i \in [0, 1]$ — относительная частота элементов множества, принадлежащих i-му классу (принимает 0 – если все элементы относятся к одному классу, 1 – когда классы представлены в равных пропорциях и равновероятны).

3) определить и оценить новый атрибут в случае некорректного выбора;

4) преобразовать предков «пустого» (куда не попал ни один элемент) узла в лист, если был сформирован таковой.

Построение дерева приходится повторять для каждого следующего прогнозируемого значения. Из-за высокой погрешности прогнозирования данный метод не подходит для долгосрочного прогнозирования [28, 29, 30, 31]).

2.5 Модель на цепях Маркова

Цепь Маркова — это математическая модель, которая используется для моделирования случайных процессов, происходящих в течение определенного периода времени [4, 3, 7, 32]. Она состоит из набора состояний и переходов между ними [32, 3]. Возможность перехода из одного состояния в другое зависит исключительно от текущего состояния, а не от каких-либо прошлых событий. Данное условие также называют марковским свойством процесса [4, 3, 7, 32].

Пример цепи Маркова для процесса, имеющего три состояния, представлен на рисунке 2.4, где $S1$, $S2$, $S3$ — состояния процесса $Z(t)$, а вероятность перехода из состояния:

— S1 в S2 равна 0.5,

— S2 в S1 равна 0.0,

— S1 в S3 равна 0.25,

— S3 в S2 равна 0.33 и так далее.

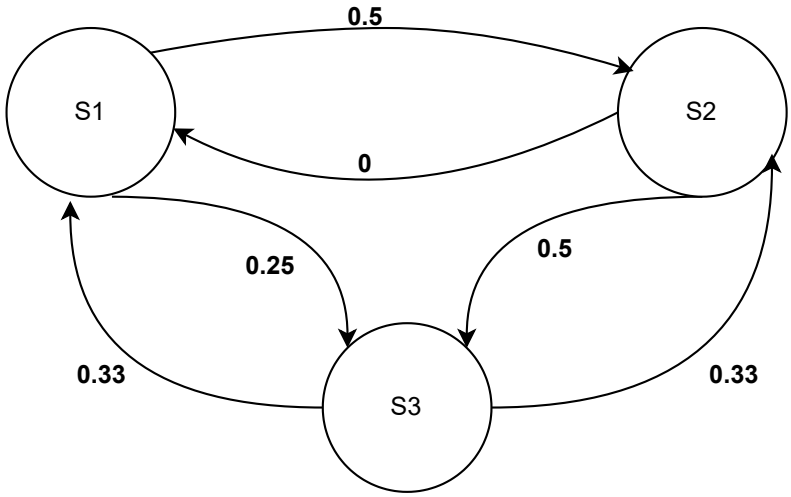


Рисунок 2.4 – Цепь Маркова

Для расчета динамики цепи достаточно рассмотреть два аспекта:

— *вектор исходного распределения вероятностей* A — вектор, каждое i-ое значение в котором, соответствует вероятности того, что система находится в i-ом состоянии [1]. Например, для модели из трех состояний:

$$A = (0.0, 0.5, 0.5); \tag{2.20}$$

— матрицу переходных вероятностей P, представляющую собой матрицу, каждое значение (i, j) которой соответствует вероятности того, что элемент перейдет из состояния s_i в состояние s_j на следующем шаге процесса [1]. Например, для модели на рисунке выше:

$$P = \begin{pmatrix} 0.25, 0.50, 0.25 \\ 0.00, 0.50, 0.50 \\ 0.33, 0.33, 0.33 \end{pmatrix}. \tag{2.21}$$

Чтобы определить вектор распределения вероятностей на следующем шаге необходимо вычислить произведение вектора A и матрицы P [7]. Для рассматриваемого примера:

$$(0.00, 0.50, 0.50) = \begin{pmatrix} 0.25, 0.50, 0.25 \\ 0.00, 0.50, 0.50 \\ 0.33, 0.33, 0.33 \end{pmatrix} = (0.165, 0.415, 0.420). \quad (2.22)$$

Следовательно, вероятность того, что цепь находится в состоянии s_i после n шагов, является i-ой записью в векторе [1]:

$$A_n = A_{n-1}P. \quad (2.23)$$

Основные этапы алгоритма построения модели временного ряда на цепях Маркова:

1) выделить состояния временного ряда;

2) проверить, можно ли считать рассматриваемый процесс Марковским;

3) вычислить матрицу переходных вероятностей;

4) определить вероятностный вектор, представляющий некоторое начальное распределение;

5) вычислить произведение матрицы и вектора n раз для получения вектора распределения вероятностей.

Рассмотрев метод прогнозирования на цепях Маркова, выделим следующие особенности его применения:

— необходимо выделить состояния временного ряда. Данное действие является дополнительным и зависит от сферы применения временного ряда;

— прогнозируемый ряд должен являться Марковским процессом;

— единообразие анализа и проектирования [3].

2.6 Сравнение методов прогнозирования временных рядов

Результаты классификации методов прогнозирования временных рядов приведены в таблицах 2.1 и 2.2.

Таблица 2.1 – Классификация методов прогнозирования временных рядов (часть 1)

классификационный параметр	методы прогнозирования								
	на цепях Маркова	на классификационно – регрессионных деревьях	экспоненциального сглаживания	регрессионные			авторегрессионные		
				простая линейная	множественная линейная	нелинейная	ARIMAX, GARCH, ARDLM	EMMSP	
тип модели	структурная			статистическая					
необходимость преобразовывать данные временного ряда перед их прогнозированием	надо выделить состояния модели	надо построить дерево	не надо						
количество учитываемых внешних факторов	любое	любое	0	1	любое	1	любое	1	
тип учитываемых внешних факторов	категориальные и дискретные		только дискретные						

Таблица 2.2 – Классификация методов прогнозирования временных рядов (часть 2)

классификационный параметр	методы прогнозирования							
	на цепях Маркова	на классификационно – регрессионных деревьях	экспоненциального сглаживания	регрессионные			авторегрессионные	
				простая линейная	множественная линейная	нелинейная	ARIMAX, GARCH, ARDLM	EMMSP
область применения	неприменима к долгохранимым или не выполняющим Марковское свойство временным рядам	необходима возможность принятия решения, когда стоит прекратить дальнейшие ветвления дерева		отсутствие возможности моделирования нелинейных процессов		процесс должен иметь известную заранее функциональную зависимость		неравностоящие, стационарные и нестационарные ряды

Подводя итоги, можно заметить, что статистические и структурные модели имеют ряд различий. Статистические модели не требуют специальной обработки дискретных данных перед применением методов прогнозирования, в отличие от рассмотренных структурных методов: для цепей Маркова необходимо выделить состояния модели, а в случае классификационно – регрессионной модели нужно построить одноименное дерево. Данная особенность позволяет учитывать влияние внешних факторов, которые не являются дискретными, что невозможно в рассмотренных статистических моделях.

С точки зрения количества учитываемых внешних дискретных факторов классифицируем методы следующим образом:

— без учета внешних факторов: модель экспоненциального сглаживания;

— с учетом одного дискретного внешнего фактора: некоторые типы регрессионных моделей и авторегрессионная модель по выборке максимального подобия;

— с учетом любого количества внешних факторов: структурные модели, модель множественной регрессии и большинство авторегрессионных моделей.

Все рассмотренные модели имеют различную область применения, поэтому при выборе модели прогнозирования необходимо проверить, удовлетворяет ли временной ряд упомянутым требованиям.

ЗАКЛЮЧЕНИЕ

Являясь субъектом многообразных явлений и процессов, мы нуждаемся в разнообразных технологиях наблюдения, анализа и прогнозирования явлений, описываемых большим объемом информации. Одним из средств достижения данных практических целей является использование временных рядов. Реализуя поставленные в работе задачи, мы:

— проанализировали предметную область «временных рядов»;

— сформулировали критерии сравнения методов хранения и прогнозирования временных рядов;

— описали и классифицировали методы хранения и прогнозирования временных рядов.

В работе выделены параметры и произведена классификация систем хранения разных видов с целью определения их области применения для практического использования следующим образом:

— Cassandra — метод с автоматизированной системой сортировки данных по времени и удаления устаревшей информации;

— Cassandra и OpenTSDB — системы, отвечающие требованиям отказоустойчивости, масштабируемости и приоритетности скорости записи данных по отношению к скорости их изменения;

— OpenTSDB — система, в которой есть инструменты для интеллектуального анализа временных рядов и встроенный модуль для визуализации данных;

— Файловая система дает возможность максимально сжать информацию.

Методы прогнозирования временных рядов дают возможность предугадать динамику отслеживаемых процессов. В работе были рассмотрены методы построения статистических моделей (экспоненциального сглаживания, регрессионные, авторегрессионные) и структурных моделей (на цепях Маркова и на классификационно-регрессионных деревьях).

С точки зрения необходимости специальной обработки данных перед прогнозированием и возможности учета влияния внешних категориальных факторов можно разделить модели на группы:

— статистические модели, не требующие специальной обработки данных и не учитывающие влияние внешних категориальных факторов;

— структурные модели, которые требуют специальной обработки данных и учитывают влияние внешних категориальных факторов.

Учитывая количество учитываемых внешних дискретных факторов, классифицируем методы следующим образом:

— без учета внешних факторов: модель экспоненциального сглаживания;

— с учетом одного дискретного внешнего фактора: простая линейная и нелинейная регрессии и авторегрессионная модель по выборке максимального подобия;

— с учетом любого количества внешних факторов: структурные модели, модель множественной регрессии и авторегрессионные модели.

Кроме того, все рассмотренные модели имеют различную область применения.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Белоусова Е.Е., Ракитский А.А. Особенности применения методов на основе марковских цепей для прогнозирования временных рядов // Сибирский государственный университет телекоммуникаций и информатики 2023.

2. Иванова Е.В., Цымблер М.Л. Обзор современных систем обработки временных рядов // Вестник ЮУрГУ. Серия: Вычислительная математика и информати- ка. 2020. Т. 9, № 4. С. 79–97.

3. Чучуева И.А. Модель прогнозирования временных рядов по выборке максимального подобия.

4. Е.М. Бронштейн, А.И. Авзалова «Прогнозирование цены акции на основе свойств цепей Маркова» // ЭКОНОМИКА И МАТЕМАТИЧЕСКИЕ МЕТОДЫ. 2015. №3.

5. К.Л. Мамаев, П.П. Тутубалин «Прогнозирование будущих отчетных периодов на основе временных рядов» // XXII ТУПОЛЕВСКИЕ ЧТЕНИЯ 2015.

6. Н.П. Сидорова, Д.С. Демина «Методы прогнозирования на основе анализа временных рядов» // Информационно – технологический вестник 2017.

7. А.А. Мальцева «Модель прогнозирования для таргетированной рекламы на основе цепей Маркова» // ПАРАДИГМА УСТОЙЧИВОГО РАЗВИТИЯ СОЦИАЛЬНО-ЭКОНОМИЧЕСКИХ СИСТЕМ НА МИКРО- И МАКРОУРОВНЯХ 2022.

8. С.А. Чернецов, И.А. Чучуева «Прогнозирование уровня глюкозы в крови больных инсулинозависимым диабетом нейронными сетями и методом экстраполяции по выборке максимального подобия» // Машиностроение и компьютерные технологии 2010.

9. А.Я. Сидорин «Полуденный эффект во временных рядах землетрясений и сейсмического шума» // Доклады академии наук 2005.

10. Д.Г. Логунов «Применение методов и моделей прогнозирования временных рядов для оценки циклической нагрузки в облачных системах» // Неделя науки СПБПУ 2020.

11. А.М. Владимирович АППРОКСИМАЦИИ ЭКСПОНЕНТАМИ ВРЕМЕННОГО КАРДИОЛОГИЧЕСКОГО РЯДА НА ОСНОВЕ ЭКГ // ВК. 2010. №9.

12. Нильсен Эйлин. Практический анализ временных рядов: прогнозирование со статистикой и машинное обучение. Вильямс, 2021. — С. 544.

13. Json [Электронный ресурс]. — Режим доступа: `https://www.json.org/json-en.html` (дата обращения: 20.10.2023).

14. R2Time: A Framework to Analyse Open TSDB Time-Series Data in HBase [Электронный ресурс]. — Режим доступа: `https://ieeexplore.ieee.org/document/7037792` (дата обращения: 20.10.2023).

15. Джефф Карпентер Эбен Хьюитт. Cassandra. Полное руководство.

16. Репликация [Электронный ресурс]. — Режим доступа: `https://learn.microsoft.com/ru-ru/sql/relational-databases/replication/sql-server-replication?view=sql-server-ver15` (дата обращения: 20.10.2023).

17. Д.Е. Намиот «Базы данных временных рядов и средства обработки» [Электронный ресурс]. — Режим доступа: `http://pzs.dstu.dp.ua/DataMining/times/bibl/time-series0.pdf` (дата обращения: 11.12.2023).

18. Н.В. Логачева, К.С. Пузырева, М.Л. Ладонычева МАСШТАБИРУЕМЫЕ РАСПРЕДЕЛЕННЫЕ ХРАНИЛИЩА. CASSANDRA или HBASE? // Инновационная наука 2022.

19. С.А. Ямашкин М.А. Скворцов М.В. Большакова А.А. Ямашкин СРАВНИТЕЛЬНЫЙ АНАЛИЗ ПОДХОДОВ К УПРАВЛЕНИЮ

БАЗАМИ ДАННЫХ ДЛЯ ОРГАНИЗАЦИИ ХРАНИЛИЩА РЕПОЗИТОРИЯ НЕЙРОСЕТЕВЫХ МОДЕЛЕЙ // Современные наукоемкие технологии 2021 №6 (часть 1).

20. А.П. Афонин Проектирование системы анализа производительности в среде Kubernetes // Санкт-Петербургский политехнический университет Петра Великого. Институт компьютерных наук и технологий 2022.

21. Е.В. Иванова М.Л. Цымблер ОБЗОР СОВРЕМЕННЫХ СИСТЕМ ОБРАБОТКИ ВРЕМЕННЫХ РЯДОВ // Вестник Южно-Уральского государственного университета. Серия: Вычислительная математика и информатика 2020.

22. Толковый словарь Ожегова // Москва Русский язык 1990.

23. Ловушки при создании моделей прогнозирования: как в них не попасть и как из них выбраться, если попали [Электронный ресурс]. — Режим доступа: `https://www.mbureau.ru/articles/lovushki-pri-sozdanii-modeley-prognozirovaniya/-kak-v-nih-ne-popast-i-kak-iz-nih-vybratsya` (дата обращения: 20.10.2023).

24. Модель прогнозирования ARIMAX: расширение [Электронный ресурс]. — Режим доступа: `https://www.mbureau.ru/blog/model-prognozirovaniya-arimax-integraciya` (дата обращения: 20.10.2023).

25. А.С. Аникин, Г.Д. Говжеев «Применение регрессионного анализа для иссле- дования временных рядов» // Актуальные исследования. 2022. №6 (85). С. 18-22.

26. Цыплаков В.И. Суслов Н.М. Ибрагимов Л.П. Талышева А.А. Эконометрия. Новосибирский государственный университет, 2005. — С. 741.

27. Модель скользящего среднего [Электронный ресурс]. — Режим доступа: `https:`

//bstudy.net/708118/ekonomika/model_skolzyaschego_srednego (дата обращения: 20.10.2023).

28. Применение системно-аналитического метода «Дерево решений» с методом выбора атрибута cart для построения системы краткосрочного прогнозирования // Вестник Самарского государственного технического университета. Серия: Технические науки 2013.

29. Деревья решений — один из методов автоматического анализа данных. [Электронный ресурс]. — Режим доступа: https://loginom.ru/blog/decision-tree-p1 (дата обращения: 20.10.2023).

30. Методические указания по лабораторной работе «Деревья решений» [Электронный ресурс]. — Режим доступа: https://dispace.edu.nstu.ru/didesk/file/get/198181 (дата обращения: 20.10.2023).

31. Построение деревьев регрессии [Электронный ресурс]. — Режим доступа: https://ranalytics.github.io/data-mining/043-Decision-Trees.html (дата обращения: 20.10.2023).

32. Использования цепей Маркова для моделирования естественного языка» [Электронный ресурс]. — Режим доступа: https://www.geeksforgeeks.org/markov-chains-in-nlp/ (дата обращения: 20.10.2023).