ИУ7-55Б 17_GAV Тютичкин

Введение:

CUDA – это программно-аппаратная архитектура, призванная увеличить производительность вычислений при помощи использования графических процессоров NVIDIA.

1 Аналитическая часть

1.1 Технология GPGPU

GPGPU (General-purpose graphics processing units) – это технология, которая позволяет использовать графический процессор, предназначенный для компьютерной графики, при выполнении общих вычислений, производимых центральным процессором.

1.2 Основные модули CUDA

1.2.1 Сетка

Сетка — это группа потоков, выполняющих одно и то же ядро. Эти потоки не синхронизированы. Каждый вызов CUDA со стороны процессора осуществляется через одну сетку. Запуск сетки на процессоре является синхронной операцией, но одновременно могут работать несколько сеток. В системах с несколькими графическими процессорами сетки не могут использоваться совместно несколькими графическими процессорами, поскольку для максимальной эффективности они используют несколько сеток.

1.2.2 Блок

Каждый блок представляет собой логическую единицу, содержащую ряд координирующих потоков и определенный объем общей памяти. Все блоки в сетке используют одну и ту же программу.

1.2.3 Поток

Поток - это наименьшая вычислительная единица в архитектуре CUDA. Все потоки в блоке могут выполнять одну и ту же программу, но с разными данными.

1.2 Архитектура CUDA

Архитектура CUDA позволяет использовать графический процессор для повышения производительности параллельных вычислений. Она представляет собой набор инструментов и библиотек для работы с графическим процессором, основанных на технологии GPGPU.

Архитектура разбивает устройство на сетки, блоки и потоки в иерархической структуре, как показано на рис. 1. Поскольку в одном блоке имеется несколько потоков, а также несколько блоков в одной сетке и несколько сеток в одном графическом процессоре, параллелизм, достигаемый с помощью такой иерархической архитектуры, огромен.

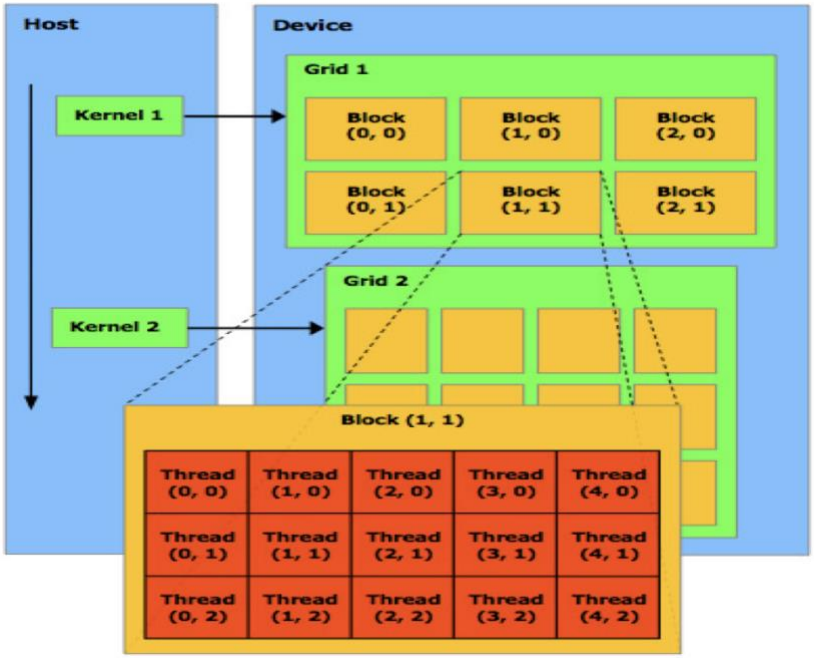


Рис 1. Архитектура CUDA