ИУ7-51Б, 03_ZHA, Вылегжанина Алёна

Хранение:

- Cassandra.

Прогнозирование:

- модель на цепях Маркова (Markov Chains);
- модель по выборке максимального подобия (MMSP).

Введение:

В философском смысле сама жизнь - это движение, то есть процесс.

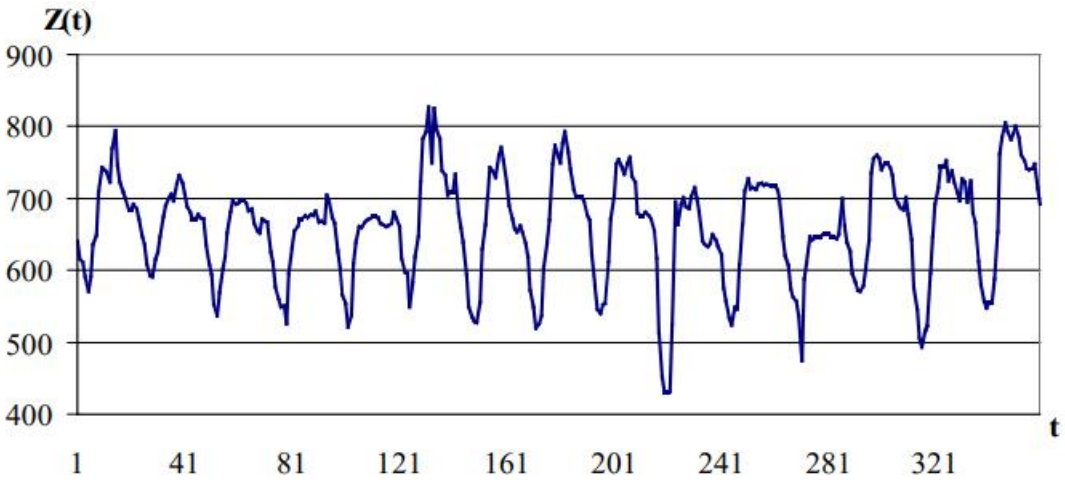
Мы включены в разнообразные процессы: .... Независимо от того являемся ли мы их источником или его участником, или просто подвержены его влиянию нам требуются технологии наблюдения, использования и прогнозирования большого объёма информации.

Задача воспроизведения источника информации, с целью анализа данных, поиска основных закономерностей и структур, а также прогнозирования возможных будущих значений решается по средством использования временных рядов [1].

Под временным рядом подразумевается последовательность наблюдений некоторого признака (случайной величины) x в последовательные моменты времени [2]. Элементы временного ряда включает в себя два обязательных параметра — отметку времени и значение показателя ряда, соответствующее указанной отметке времени.

Область применения временных рядов охватывает различные сферы: экономика (анализ и прогнозирование курсов акций[1-2 Soder.indd (elibrary.ru)],)

На рисунке 1.1 представлен пример временного ряда цен на электроэнергию европейской территории РФ



Временные ряды дают возможность предугадать динамику отслеживаемых процессов. Прогноз основывается на данных, которые фиксируются на протяжении некоторого времени, что требует организации их хранения.

В данной работе будут рассмотрены методы хранения и прогнозирования временных рядов.

Методы хранения.

Необходимым условием для работы с временными рядами является организация хранения отслеживаемых данных.

В силу особенностей временных рядов и их обработки система хранения должна решать следующие задачи:

Обозначим ключевые требования к средствам хранения временных рядов.

• Операции записи преобладают над операциями чтения [7].

• Данные записываются, считываются и обновляются не случайным образом, а во временном порядке [7].

• Масштабируемость - добавить пояснение

• Отказоустойчивость - добавить пояснение

В качестве методов хранения можно выделить следующие подходы, которые мы планируем рассмотреть в данной работе:

использование нереляционных - Cassandra

специализированных для временных рядов баз данных - TSDB (тема другого члена группы)

использование обычных файлов (тема другого члена группы)

Cassandra

Одним из способов хранения временных рядов является использование Apache Cassandra - это база данных, которая является:

- *распределенной* - обеспечивает работу на нескольких машинах, в дальнейшем называемые узлами, которые пользователем представляются как единое целое [3];
- *децентрализованной* - все узлы являются равноправными [3];
- *эластично масштабируемой* - обеспечивает возможность добавлять и убирать узлы не прерывая работы системы, что является специальным свойством горизонтальной масштабируемости (то есть механического увеличения пропускной способности оборудования путём добавления памяти в уже имеющуюся машину) 3];
- *отказоустойчивой* - предполагает замену повреждённые узлов без простоя, за счет их репликации на несколько узлов [3] (репликация представляет собой набор технологий копирования и распространения данных и объектов между узлами, а также включая синхронизацию этих узлов для поддержания их согласованности [4]);
- *допускающей настройку согласованности* (согласованность означает, что операция чтения всегда возвращает последнее записанное значение) - возможно настроить количество узлов, которые должны подтвердить завершение операции обновления данных [3].

Основными структурами данных в Cassandra являются:

- *столбец* - пара имя-значение;
- *строка* - контейнер для упорядоченной коллекции столбцов на которые можно сослаться по первичному ключу;
- *таблица* - контейнер для упорядоченной коллекции строк;
- *пространство ключей* - контейнер таблиц;
- *кластер* - контейнер пространств ключей, расположенных в одном или нескольких узлах [3].

Таким образом, столбец - самая элементарная структурная единица в модели данных Cassandra, и ему присущи следующие характеристики:

- имя;
- значение;
- тип;
- временная метка, которая генерируется при каждом обновлении столбца;
- время жизни - указывает время хранения значения столбца [3].

Уточнив основные понятия базы данных, рассмотрим особенности Cassandra применительно к хранению временных рядов.

Модель данных организует хранение временного ряда, где *ключ для строки* – имя для нашего измерения, *имя столбца* – время измерения, *значение столбца* – измеренное значение [5]. Данная структура позволяет выбрать как индивидуальное значение, так и набор значений для заданного интервала какого-либо измерения [5].

Кроме того, для каждого столбца хранится время жизни, которое позволяет автоматизировать процесс удаления устаревших данных, а также временная метка, которая используется для:

- разрешения конфликтов при изменении одного и того же значения со стороны нескольких клиентов [3];
- организации автоматической сортировки данных по времени [5].

В случае обработки временных рядов скорость поступления данных имеет большее значение, чем скорость их изменения, потому что информация однородна и фактически обрабатывается только небольшая часть из всего объёма хранимой информации [5]. Данные особенности позволяют выделить Cassandra, как нереляционную БД (скорость добавления данных в NoSQL системах выше, чем в SQL системах) [5].

Cassandra является распределённой и децентрализованной, в следствии этого можно выделить следующие её аспекты:

- отказоустойчивость - гарантия сохранности информации за счёт репликации [6];
- масштабируемость - увеличение объёма хранимых данных возможно посредством добавления узла в кластер [6];
- слабая согласованность данных - отсутствие контроля актуальности читаемой информации [3]. Данная особенность может быть скорректирована настройкой согласованности.

Прогнозирование

Чучуева И. А. «МОДЕЛЬ ПРОГНОЗИРОВАНИЯ ВРЕМЕННЫХ РЯДОВ ПО ВЫБОРКЕ МАКСИМАЛЬНОГО ПОДОБИЯ»

Под прогнозированием понимают предсказание будущего с помощью научных методов. Необходимо различить два взаимосвязанных понятия — метод прогнозирования и модель прогнозирования.

Метод прогнозирования представляет собой последовательность действий, которые нужно совершить для получения модели прогнозирования временного ряда.

Модель прогнозирования есть представление зависимости будущего значения от прошлого. Способ задания этой зависимости может быть различным.

В *статистических* моделях функциональная зависимость между будущими и фактическими значениями временного ряда, а также внешними факторами *задана аналитически*.

К статистическим моделям относятся следующие группы:

— регрессионные модели;

— авторегрессионные модели;

- модель по выборке максимального подобия;

— модели экспоненциального сглаживания.

В *структурных* моделях зависимость будущего значения от прошлого задается в виде некоторой структуры и правил перехода по ней.

К структурным моделям относятся следующие группы:

— нейросетевые модели;

— модели на базе цепей Маркова;

— модели на базе классификационно-регрессионных деревьев.

elibrary_48124652_97699410.pdf



Рисунок 1 — Классификации моделей и методов прогнозирования

Необходимо отметить, что названия моделей и соответствующих методов как правило совпадают.

Основываясь на полученных и хранимых данных, можно прогнозировать дальнейшее поведение временных рядов. В нашей работе будут рассмотрены следующие:

- ...

- метод получения модели на цепях Маркова;

- метод получения модели по выборке максимального подобия без учета внешних факторов.

Модель на цепях Маркова.

Цепь Маркова — это математическая модель, которая используется для моделирования случайных процессов, происходящих в течение определённого периода времени. Она состоит из набора состояний и переходов между ними. Возможность перехода из одного состояния в другое зависит исключительно от текущего состояния, а не от каких-либо прошлых событий. Данное условие также называют марковским свойством процесса.

Пример цепи Маркова для процесса, имеющего три состояния, представлен на рис. 1.6.

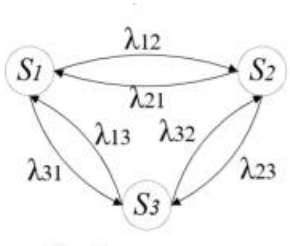


Рис. 2. Пример цепи Маркова

Где S1 ,..., S3 — состояния процесса Z(t) ; 12 — вероятность перехода из состояния S1 в состояние S2 , 23 — вероятность перехода из состояния S2 в состояние S3 и т. д.

Для расчёта динамики цепи, необходимо лишь два аспекта:

- вектор исходного распределения вероятностей A - вектор, каждое i-ое значение в котором соответствует вероятности того, что система находится в i-ом состоянии. Например, для модели из трех состояний: $(0.0, 0.5, 0.5)$
- матрица переходных вероятностей P представляет собой матрицу, каждое значение (i, j) которой соответствует вероятности того, что элемент перейдет из состояния si в состояние sj на следующем шаге процесса[]. Например, для модели на рисунке выше $\begin{pmatrix} 0.25 & 0.50 & 0.25 \\ 0.00 & 0.50 & 0.50 \\ 0.33 & 0.33 & 0.34 \end{pmatrix}$.

Чтобы определить вектор распределения вероятностей на следующем шаге необходимо вычислить произведение вектора A и матрицы P. Для рассматриваемого примера:

$$: (0.0, 0.5, 0.5) \begin{pmatrix} 0.25 & 0.50 & 0.25 \\ 0.00 & 0.50 & 0.50 \\ 0.33 & 0.33 & 0.34 \end{pmatrix} = (0.165, 0.415, 0.420)$$

Следовательно, вероятность того, что цепь находится в состоянии si после n шагов, является i-ой записью в векторе:

$$A_n = A_{n-1}P$$

Основные этапы алгоритма построения модели временного ряда на цепях Маркова:

1) выделить состояния временного ряда;
2) проверить, можно ли считать рассматриваемый процесс Марковским;
3) вычислить матрицу переходных вероятностей;
4) определить вероятностный вектор, представляющий некоторое начальное распределение;
5) вычислить произведение матрицы и вектора n раз для получения вектора распределения вероятностей.

Вывод:

Рассмотрев метод прогнозирования на цепях Маркова, выделим следующие аспекты его применения:

- необходимо выделить состояния временного ряда. Данное действие является дополнительным и зависит от сферы применения временного ряда;
- прогнозируемый ряд должен являться Марковским процессом;
- единообразие анализа и проектирования.

Модель по выборке максимального подобия.

Временной ряд обозначим $Z_1^N=(z_1, z_2, z_3, \ldots, z_N)$. . Набор последовательных значений $Z_t^M=(z_t, z_{t+1}, z_{t+2}, \ldots, z_{t+M-1})$, , лежащих внутри временного ряда z_1^N, назовём *выборкой* из этого ряда длины $M \in [1:(N-1)];$ с моментом начала отсчета $t \in [1:(N-M)].$. Разность начал отсчетов выборок z_t^M и z_{t-k}^M будем называть *задержкой* $k \in [1:(t-1)].$

Выборки обладают свойством подобия, чем мы и воспользуемся для прогнозирования временного ряда []. Идея

метода заключается в построении ожидаемой выборки с помощью аппроксимации уже существующей. С целью реализации данной технологии следует ответить на следующие вопросы.

1. Как аппроксимировать выборки?

выборки $\boldsymbol{Z}_{T-M+1}^{M}$ при помощи выборки $\boldsymbol{Z}_{T-M+1-k}^{M}$. Обозначим момент времени $T-M+1=t$ и решим данную задачу.

Вычислим аппроксимированные значения выборки

$$\hat{\boldsymbol{Z}}_{t}^{M}=\alpha_1 \boldsymbol{Z}_{t-k}^{M}+\alpha_0 \boldsymbol{I}^{M}. \qquad (3.2)$$

Согласно методу наименьших квадратов, коэффициенты аппроксимации определим, исходя из уравнения

$$\boldsymbol{Z}_X \cdot \boldsymbol{A}=\boldsymbol{Z}_Y, \qquad (3.3)$$

где значение элементов матрицы $\boldsymbol{Z}_X$ и $\boldsymbol{Z}_Y$ определяются следующим образом:

$$\boldsymbol{Z}_X=\begin{bmatrix} \sum_{i=0}^{M-1} Z^2(k+i) & \sum_{i=0}^{M-1} Z(k+i) \\ \sum_{i=0}^{M-1} Z(k+i) & M \end{bmatrix};$$

$$,\boldsymbol{Z}_Y=\begin{bmatrix} \sum_{i=0}^{M-1} Z(k+i)\cdot Z(T-M+1+i) \\ \sum_{i=0}^{M-1} Z(T-M+1+i) \end{bmatrix}.$$

2. Какую выборку следует аппроксимировать?

Подходящую для аппроксимации выборку называют *базовой историей*. Она располагается на оси времени сразу за *выборкой максимального подобия* для новой истории - $\boldsymbol{Z}_{T-M+1}^{M}$. Новая история содержит значения процесса непосредственно перед моментом прогноза. Соответственно, чтобы вычислить базовую историю, следует определить выборку максимального подобия.

3. Как определить выборку максимального подобия для выборки новой истории?

Как следует из названия, мы ищем такую выборку, значения которой являются наиболее близкими к значениям новой истории.

Отсюда, необходимо ввести меру подобия двух выборок. Введём коэффициент ро:

$$\rho_k^M = \frac{\left|\mathrm{cov}(Z_t^M, Z_{t-k}^M)\right|}{\sqrt{D[Z_t^M]} \cdot \sqrt{D[Z_{t-k}^M]}} \in [0,1].$$

Мера подобия зависит от длины M выборок, а также от задержки k, и характеризует степень линейной зависимости указанных выборок: чем ближе к единице значение ро, тем выше их линейная зависимость. [prognozirovanie-urovnya-glyukozy-v-krovi-bolnyh-insulinozavisimym-diabetom-neyronnymi-setyami-i-metodom-ekstrapolyatsii-po-vyborke-maksimalnogo-podobiya (1).pdf].

Далее необходимо рассмотреть все возможные выборки и вычислить для них коэффициент подобия новой истории. Выборка с максимальным значением ро и будет выборкой максимального подобия.

В итоге получаем функциональную зависимость значений прогнозируемой выборки от фактически существующей:

Экстраполированные значения выборки $\hat{\boldsymbol{Z}}_{T+1}^P$ (прогноз, Forecast) определяются по формуле

$$\hat{\boldsymbol{Z}}_{T+1}^P = \alpha_1 \boldsymbol{Z}_{kmax^*+M}^P + \alpha_0 \boldsymbol{I}^P = EMMSP(M), \qquad (2.25)$$

которая представляет собой модель экстраполяции временных рядов по выборке максимального подобия (extrapolation model on most similar pattern,

Основные этапы алгоритма построения модели.
Необходимо вычислить:
1) выборку новой истории;
2) выборку максимального подобия;
3) выборку базовой истории;
4) прогнозные значения.

Выделим особенности метода прогнозирования временных рядов на модели по выборке максимального подобия:

— модель относится к классу авторегрессионных моделей прогнозирования;

— модель может работать с неравноотстоящими временными рядами;

— модель работает со стационарными и нестационарными временными рядами;

— модель имеет один параметр M - длины выборки;

— экстраполяция P значений временного ряда производится за одну итерацию.

*** Не успела отформатировать работу, добавить нормальные рисунки и формулы. ****

Источники.

1. https://elibrary.ru/download/elibrary_53949324_87954537.pdf - Белоусова Е.Е., Ракитский А.А. Особенности применения методов на основе марковских цепей для прогнозирования временных рядов
2. kizbikenov.pdf (altspu.ru) - К.О. Кизбикенов «Прогнозирование и временные ряды»
3. Джефф Карпентер, Эбен Хьюитт «Cassandra. Полное руководство»
4. Репликация SQL Server - SQL Server | Microsoft Learn
5. http://pzs.dstu.dp.ua/DataMining/times/bibl/time-series0.pdf - Д.Е. Намиот «Базы данных временных рядов и средства обработки»
6. МАСШТАБИРУЕМЫЕ РАСПРЕДЕЛЕННЫЕ ХРАНИЛИЩА. CASSANDRA ИЛИ HBASE? (cyberleninka.ru)
7. part.pdf (williamspublishing.com)- «Хранение временных рядов»
8. https://www.elibrary.ru/download/elibrary_24669862_36850259.pdf - применение модели по выборке максимального подобия.
9. https://cyberleninka.ru/article/n/prognozirovanie-urovnya-glyukozy-v-krovi-bolnyh-insulinozavisimym-diabetom-neyronnymi-setyami-i-metodom-ekstrapolyatsii-po-vyborke/viewer - применение модели по выборке максимального подобия.
10. https://unitech-mo.ru/upload/files/science/information-technology-journal/itv03_2017.pdf#page=118 - применение модели по выборке максимального подобия.
11. 1-2_Soder.indd (elibrary.ru) - цепи Маркова
12. https://www.elibrary.ru/download/elibrary_48124652_55808541.pdf#page=105 - использование модели на цепях Маркова
13. https://elibrary.ru/download/elibrary_53949324_87954537.pdf
14. Цепи Маркова в НЛП - GeeksforGeeks
Пример использования для моделирования естественного языка.
15. Чучуева Ирина Александровна «Модель прогнозирования временных рядов по выборке максимального подобия»

tsifrovaya-kriminologiya-matematicheskie-metody-prognozirovaniya-chast-1.pdf - статья про прогнозирование в криминологии.